A Basic Introduction to Artificial Neural Network (ANN)

INDEX

1. Introduction to Artificial neural networks
2. Perceptron
3. Backpropagation Neural Network
4. Hopfield memory
5. Self Organizing Map(SOM)

1. Introduction to ANN

Introduction to ANN

- Connectionism vs Symbolism

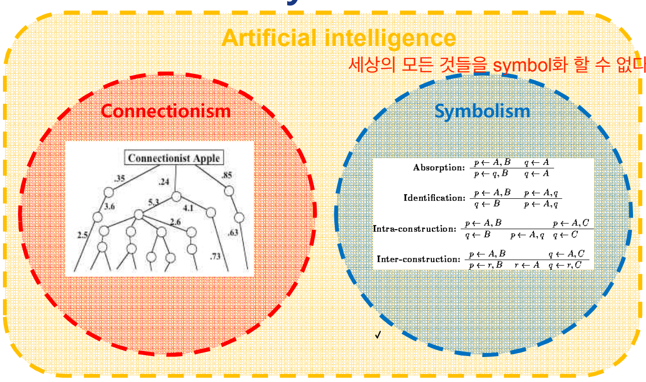

Introduction to ANN

• Connectionism vs Symbolism

- Connectionism과 Symbolism은 인공지능 분야를 대표하는 두 가지 고전적 접근방법

- **Symbolic AI**는 지식을 symbol과 그들간의 relation 또는 Logic으로 표현.
  - 문제 해결 또는 새로운 지식 추론을 위하여 symbolic instance와 그들간의 relation에 특정 algebraic Inference을 적용한다
  - e.g. Logical Inference in Ontology, Probabilistic Inference, Fuzzy inference)
- **Connectionist AI**는 지식을 network상에 분산된 형태로 표현.
  - 생명체의 신경 구조를 모방하여 지능적 프로세스를 발현시킴으로써 인식/학습/추론 문제를 해결
  - e.g. Artificial Neural Net

Introduction to ANN

• The Brain vs. Computer

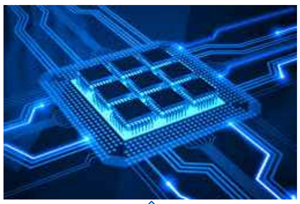

1. 10 billion neurons
2. 60 trillion synapses
3. Distributed processing
4. Nonlinear processing
5. Parallel processing

1. Faster than neuron (10^{-9}sec)
   cf. neuron: 10^{-3}sec
2. Central processing
3. Arithmetic operation (linearity)
4. Sequential processing

Introduction to ANN

- **Biological inspiration**
  - 생명체의 경우 주변 환경에 적응적 행동 및 학습을 수행함
  - 생명체는 네트워크 형태의 "신경구조(nervous system)"를 사용

<Nervous system>

Introduction to ANN

- **Biological inspiration**
  - Artificial neural network는 이러한 동물의 신경구조(nervous system)를 모방하여 기존의 Symbolic AI로 해결하기 어려할 수 없었던 문제를 해결하고자 하는 접근.
    - 신경구조(nervous system)는 **뉴런(neuron)**이라는 간단한 형태의 기본 unit의 연결망으로 구성
    - 뉴런의 기본 형태를 모사하여 신경구조의 기능과 행동을 발현하고자 함

Introduction to ANN

- **Biological inspiration**

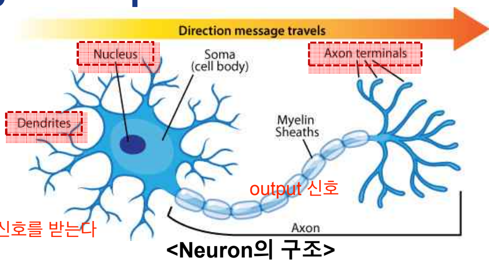

<Neuron의 구조>

- 뉴런은 Dendrites를 통해, 다수의 타 뉴런들로 부터의 “입력신호”를 전달 받음
- Nucleus(핵)을 거친 신호는 Axon terminals를 통해 다음 뉴런으로 출력 전파

Introduction to ANN

- **Biological inspiration**

w는 양수일 수도, 음수일 수도 있다
만약 w이 1이라면 100%전달이 된다
w이 -1이라면 input 값은 반대 방향으로 100%전달

p2 100
w2 -1 => x : -1

w값 자체 p가 w랑 해서 x에 얼마나 영향을 끼치는지
머신러닝에선 이 w를 학습한다

아까 뉴런 구조를 간략화하면

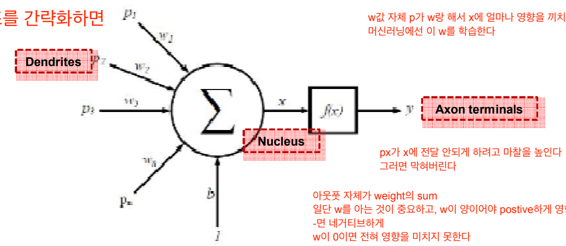

px가 x에 전달 안되게 하려고 마찰을 높인다
그러면 막혀버린다

아웃풋 자체가 weight의 sum
일단 w를 아는 것이 중요하고, w이 양이어야 postive하게 영향ㅇ르 받음
-면 네거티브하게
w이 0이면 전혀 영향을 미치지 못한다

- 뉴런의 입력, 처리, 출력(전파)를 각각 담당하는 Dendrites, Nucleus, Axon terminals를 모방한 구조
- ANN에서 위와 같은 구조의 unit을 **Perceptron**이라 한다

Types of simple ANNs

입력형식	학습방식	Artificial neural network model
이진입력	지도(supervised) 학습	Hopfield memory, BAM
실수입력	지도(supervised)학습	Perceptron, Backpropagation neural network
	비지도(unsupervised) 학습	Self-Organizing Map(SOM)

< ANN 모델 분류 예 >

2. Perceptron

Perceptron

- **What is Perceptron?**
  - Perceptron은 ANN을 구성하는 단위
  - 복수개의 Input을 입력 받은 뒤 처리를 거친 후, 하나의 Output을 반환
  - 입력 신호 p_i와 가중치 w_i의 곱을 모두 합한 값에 따라 출력신호 y의 흥분여부가 결정 된다

0하고 1 사이, 0하고 -1사이...

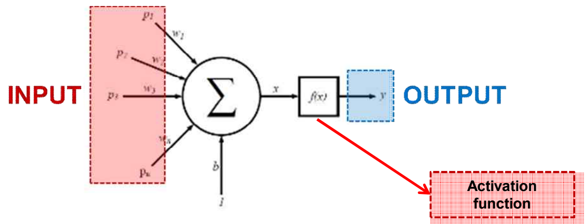

<Perceptron의 구조>

Perceptron

- **Activation function**
  - 자주 사용되는 Activation function f_n

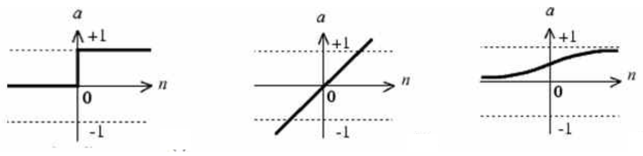

<hard limiter> <Linear> <Sigmoid>

Perceptron

- **Learning (Perceptron)**
  - 지도학습(Supervised Learning), 이진 & 아날로그 입력처리
  - 전체 출력뉴런들에 대하여 계산된 출력값과 목표값과의 차이를 최소화시킴
    → Widrow-Hoff rule(delta rule)
  - actual output desire output
    만일 계산된 출력값과 목표값 간에 차이가 없으면 연결 가중치(w_i)는 변경되지 않으며,차이가 있으면 <u>차이를 줄이는 방향으로 가중치를 변경.</u>

Perceptron

- **Widrow-Hoff rule(delta rule)**

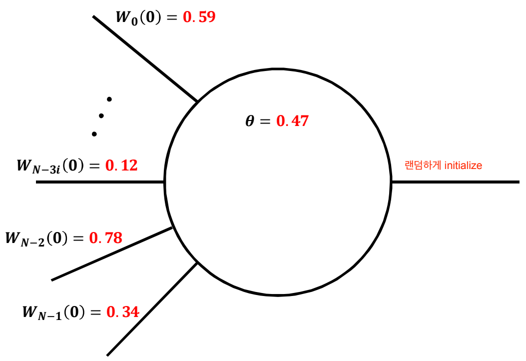

1. 가중치($\boldsymbol{W_i(0)}$)와 임계치(θ)를 임의의 작은 값으로 초기화

Perceptron

- **Widrow-Hoff rule(delta rule)** 가장 나은 weight를 구하는 것

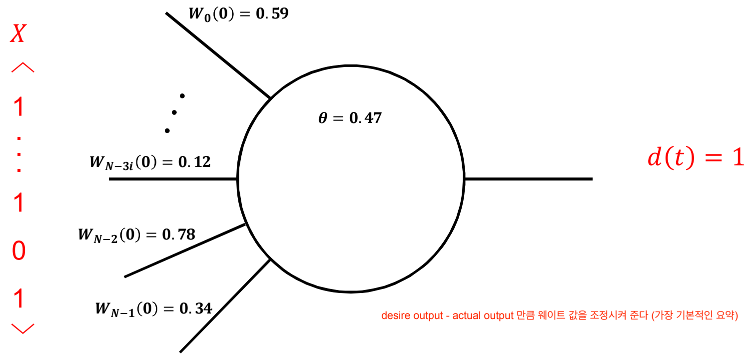

2. 새로운 입력패턴(X_0, X_1, ...)과 목표출력 패턴(d(t))을 제시

Perceptron

- **Widrow-Hoff rule(delta rule)**

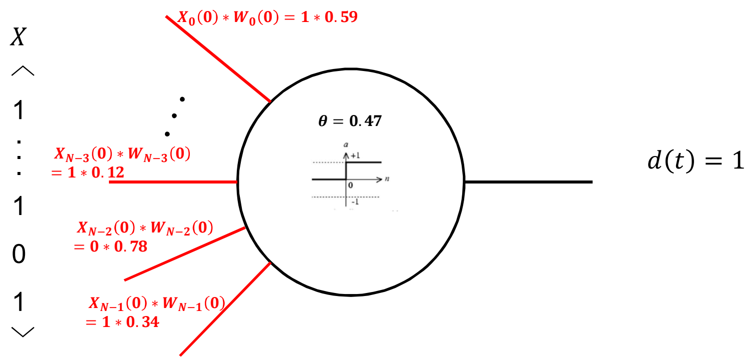

3. Activation function(hard limiter) f_n를 사용하여 실제 출력값(y(t))을 계산

Perceptron

- **Widrow-Hoff rule(delta rule)**

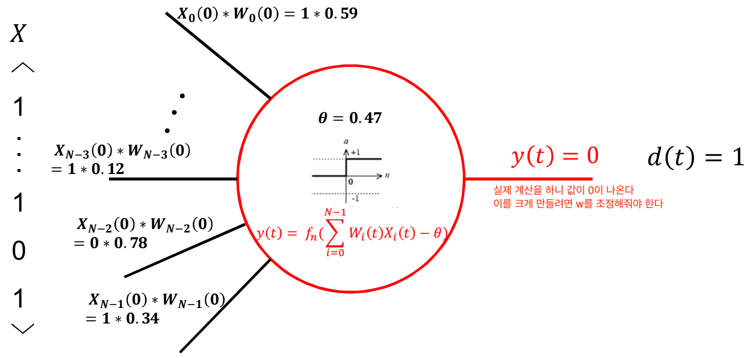

3. Activation function(hard limiter) f_n를 사용하여 실제 출력값(y(t))을 계산

Perceptron

- **Widrow-Hoff rule(delta rule)**

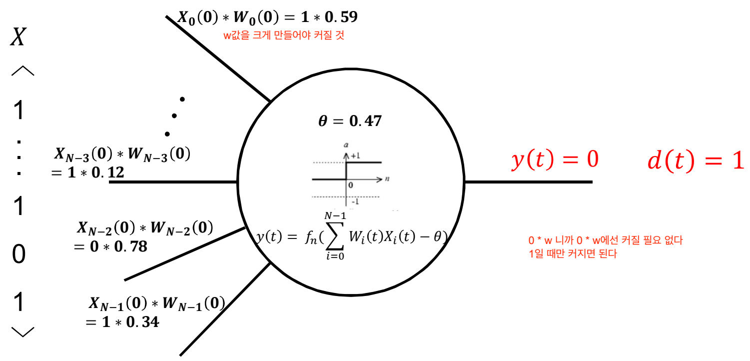

4. 목표값($d(t)$)과 출력값($y(t)$)을 이용한 가중치를 갱신

Perceptron

- **Widrow-Hoff rule(delta rule)**

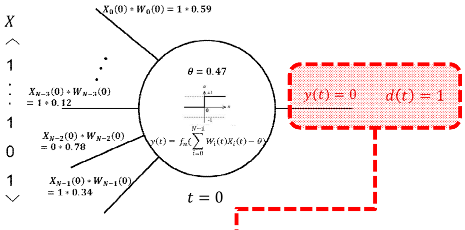

여기서 알파값을 곱하는 이유를 뒤에서 설명해준다

알파라는 아주 작은 값
10^-3 이상 작은 값

양/음으로 영향을 미쳤는지

$$W_i(t+1) = W_i(t) + \alpha[d(t) - y(t)] * X_i(t), (0 \le i \le N-1)$$

4. 목표값($d(t)$)과 출력값($y(t)$)을 이용한 가중치를 갱신

이걸 계속 반복해주면 d(t)와 y(t)가 좁아지다가
결국 0이 될 것이다. 그때까지 조정을 해주는 것이
neural을 학습시키는 방법

Perceptron

- **Example(AND Operation using Perceptron)**

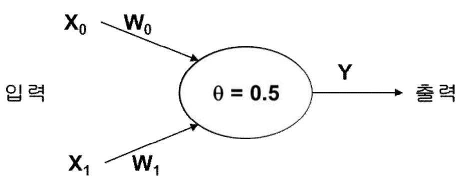

입력		출력
X_0	X_1	AND
0	0	0
0	1	0
1	0	0
1	1	1

- 뉴런에 입력되는 가중치의 합이 임계치를 초과하면 1, 아니면 0
  →Activation function → hard limiter
- AND

$$\begin{aligned} 0\times W_0 + 0\times W_1 &= 0 && < 0.5 \\ 0\times W_0 + 1\times W_1 &= W_1 && < 0.5 \\ 1\times W_0 + 0\times W_1 &= W_0 && < 0.5 \\ 1\times W_0 + 1\times W_1 &= W_0 + W_1 && > 0.5 \end{aligned}$$

0.5로 학습이 되면
00 01 10에 대해선 0이 되고
11에 대해선 1이 나온다

- W0, W1 : 0.3 or 0.4

Perceptron

- **Example**(**XOR Operation using Perceptron**)

$$
\begin{aligned}
0 \times W_0 + 0 \times W_1 &= 0 && < 0.5 \\
0 \times W_0 + 1 \times W_1 &= W_1 && > 0.5 \\
1 \times W_0 + 0 \times W_1 &= W_0 && > 0.5 \\
1 \times W_0 + 1 \times W_1 &= W_0 + W_1 && < 0.5
\end{aligned}
$$

입력		출력
X_0	X_1	XOR
0	0	0
0	1	1
1	0	1
1	1	0

→ **만족하는 W0, W1 는 존재하지 않음**

→ **하나의 Perceptron으로는 간단한 XOR 문제도 해결하지 못함**

XOR : linearly non-separable

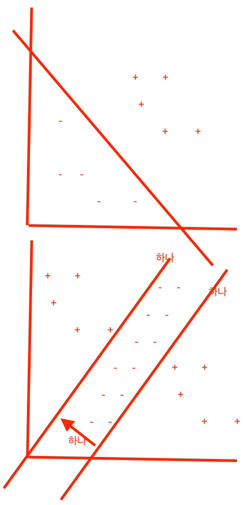

- 이러한 문제를 해결하기 위해서 2개 또는 3개의 층(layer)을 사용
- Backpropagation Neural Network (Multi-layer Perceptron)
  →3층 Perceptron으로 어떤 문제도 (근사적으로) 해결가능 Text 증명을 해 부랴따! 이과가 또~
- Perceptron은 Multi-layer Perceptron 및 Error Back propagation Algorithm 의 기반 중요중요중요~~~

neural network의 중요성은 여기에 있다리

조합으로 대부분 표현이 되지 않을 것!
그런데 뉴랄넷을 쓰면 그 함수자체가 어떤 관계라도! 상당히 정확한 정밀도로 다 표현할 수 있다는 것이 술가적으로 증명이 됐다

AI Lab, Hanyang University

y = xlogx + (cosx^2 - e^(x^5) + x^(-500)) / tanh(x^3 - 2x + e^x)

XOR 다층 퍼셉트론 예

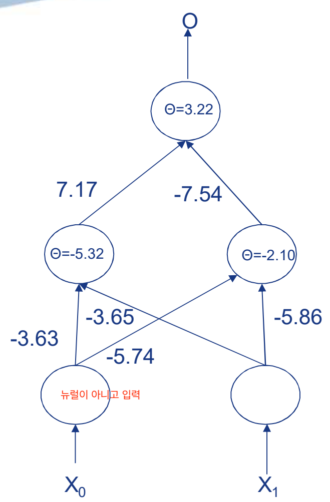

퍼셉트론 세개 씀

x_0	x_1	O
0	0	0
0	1	1
1	0	1
1	1	0

AI Lab, Hanyang University

3. Backpropagation Neural Network

Backpropagation Neural Network

- **What is Backpropagation Neural Network?**

5개 / 6개 / 3개 있는 뉴럴 넷

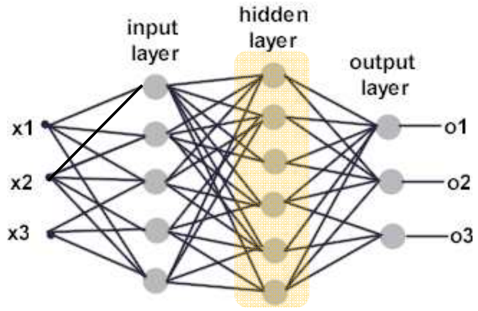

fully connect하는게 기본

<Backpropagation Neural Network>

- input layer과 output layer 사이에 하나 이상의 hidden layer을 가지는 단방향 신경회로망

Backpropagation Neural Network

퍼셉트론 하나를 주고 학습시키는 방법.
그 후에 퍼셉트론을 여러 층으로 해서 (실제로 수천, 수만개) 연결해서..
back propagation을 이해

그 후에 뉴럴넷의 basic을 이해하면 된다. 어떻게 작동되는가..로 시작
그걸 이해 못하면 그 이후는 계속 이해가 되지 않을 ㅓㅅ이다

What is Backpropagation Neural Network?

- 단층 퍼셉트론의 선형분리(linearly non-separable) 문제점을 해결(XOR operation 등 구현가능)
- **일반적인 continuous function approximation 문제 해결을 위해 널리 사용**

optimizationg할 때~
함수의 최대값 최소값은 어떻게 찾느냐~?
가장 단순한 것은 미분해서 0이 되는 지점을 찾는다 (극대 극소 찾기)

- 80년대 중반 등장한 Error Back propagation Algorithm을 바탕으로 함
  → 일반화된 델타 규칙(generalized delta rule)
- Learning?
  → 원하는 목표값(d)과 실제 출력값(o) 사이의 오차제곱합으로 정의된 Error Function의 값을 최소화하는 방식으로 학습

Backpropagation Neural Network

Learning? Error backpropagation!

모든 edge부분에 편미분을 해준다~

- Error backpropagation Algorithm 개념
  - hidden layer의 학습을 위해 output layer에서 발생한 오류를 이용하여 hidden layer 가중치 재계산
  - 이 값을 다시 input layer으로 역전파(backpropagation)시켜 가중치를 재계산
  - output layer의 오류를 Gradient Descent Method 기법으로 최소화함
- 문제점
  - 상위층의 목표값과 실제 출력값 간의 오류를 하위층으로 역전파시키는 것은 생물학적 현상과 일치하지 않음
    - ✓ 하위층의 각 뉴런이 상위층의 목표값을 알지 못하는 경우가 일반적인 생물학적 현상임
- **보편적으로 많이 사용되는 인공신경망 학습 방법**

Gradient Descent Method

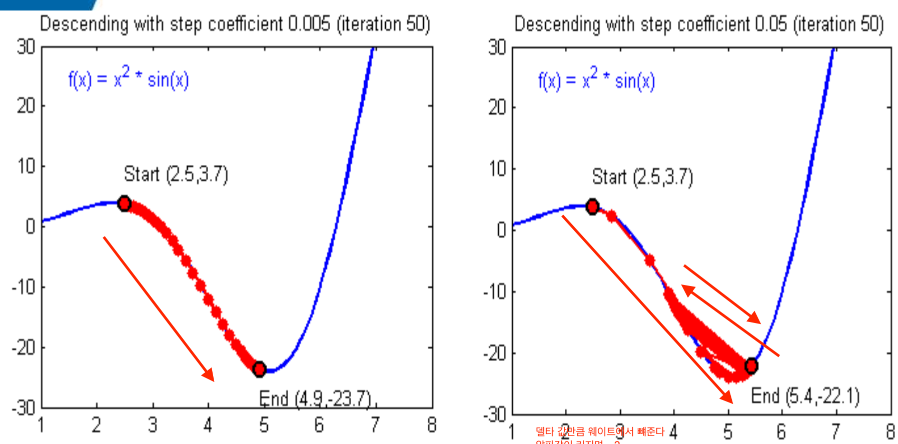

델타 값만큼 웨이트에서 빼준다
알파값이 커지면…?

수렴을 못하고 진동을 한다

아주 작은 알파값을 곱해주는 이유를 이 그림을 통해 설명해준다

Gradient Descent Method

가장 단순무식한 방법이긴 하다

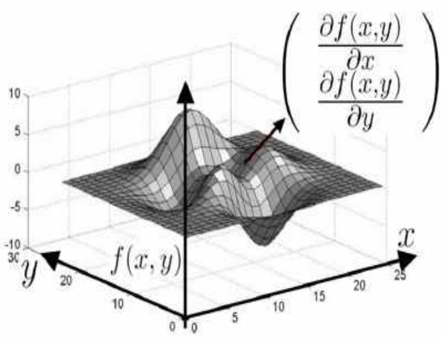

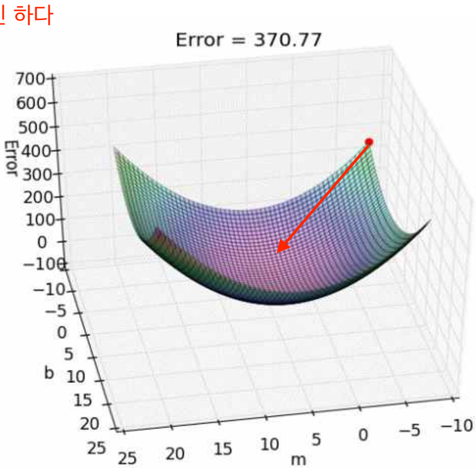

Backpropagation Neural Network

- **Learning? Error backpropagation!**

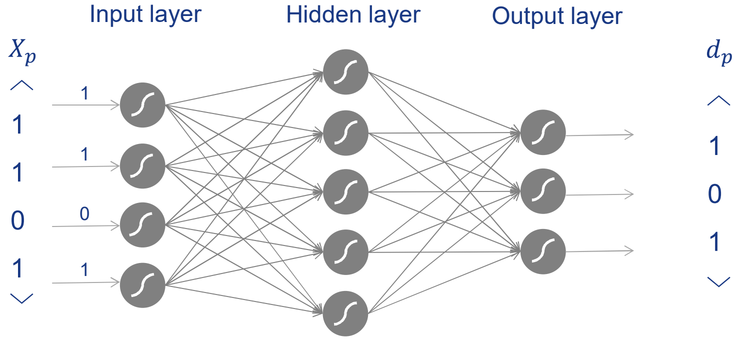

Backpropagation Neural Network

- **Learning? Error backpropagation!**

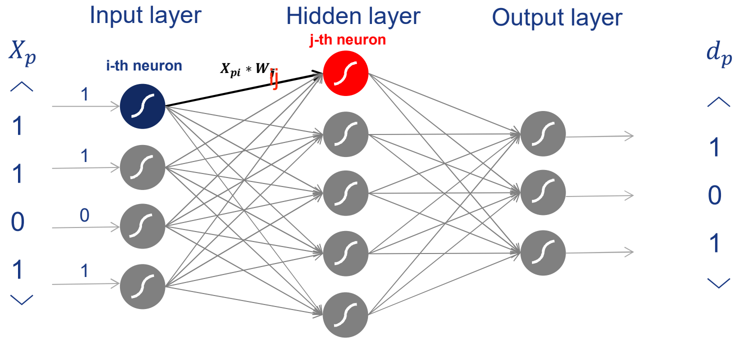

Backpropagation Neural Network

- **Learning? Error backpropagation!**

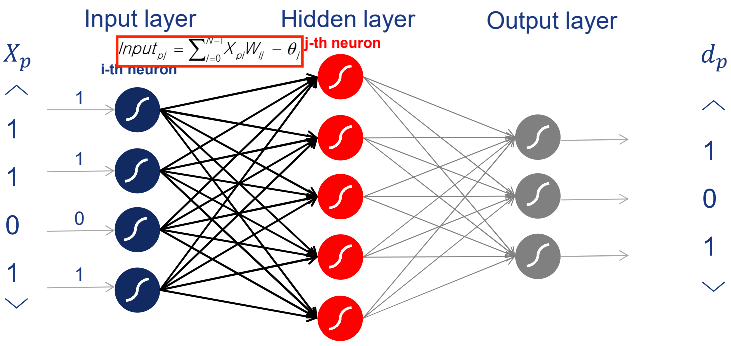

AI Lab, Hanyang University

Backpropagation Neural Network

- **Learning? Error backpropagation!**

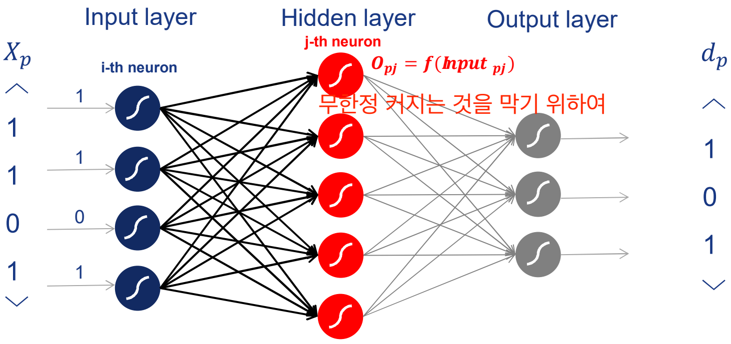

AI Lab, Hanyang University

Backpropagation Neural Network

- **Learning? Error backpropagation!**

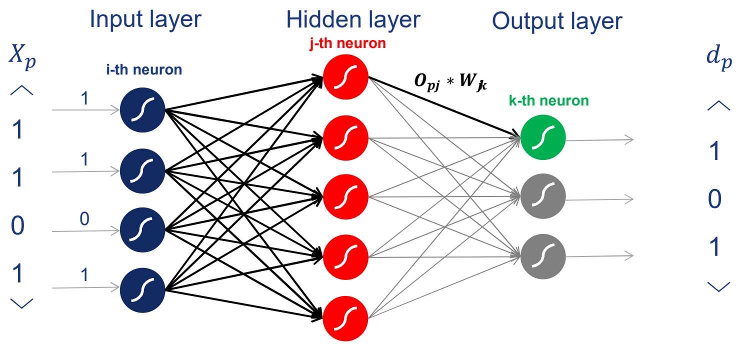

Backpropagation Neural Network

- **Learning? Error backpropagation!**

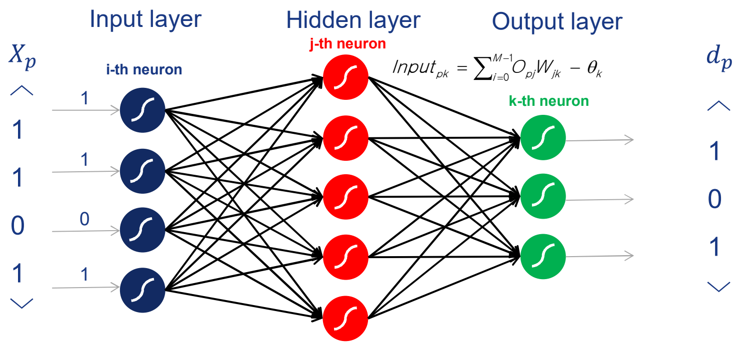

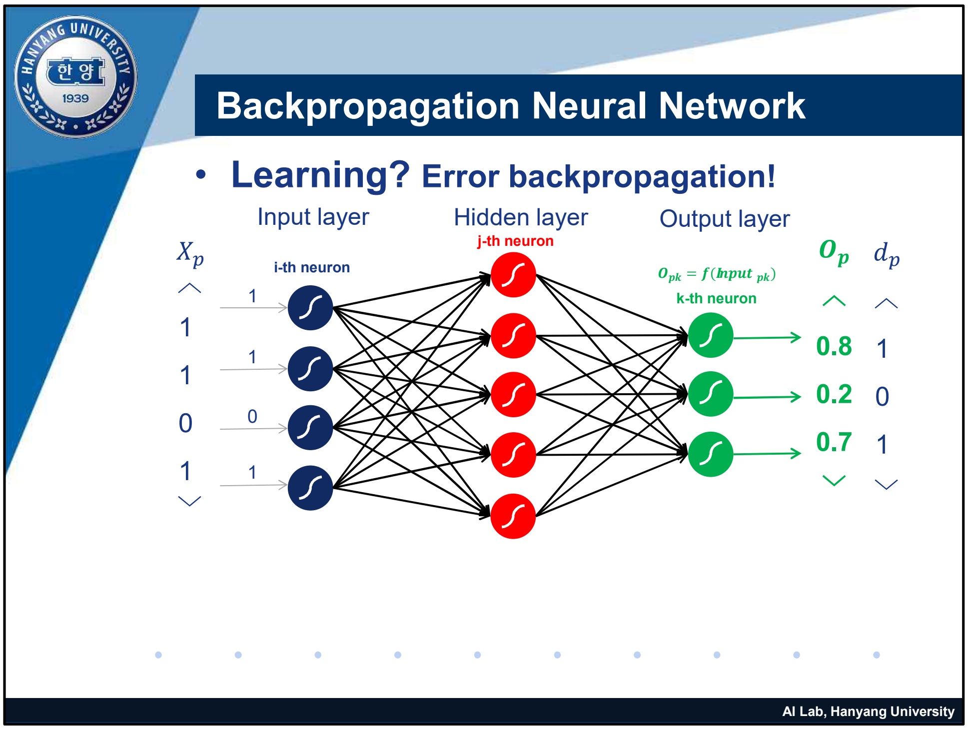

절대값을 최소로 하겠다는 것
절대값의 제곱을 최소로 하겠다는 것
모두 같다

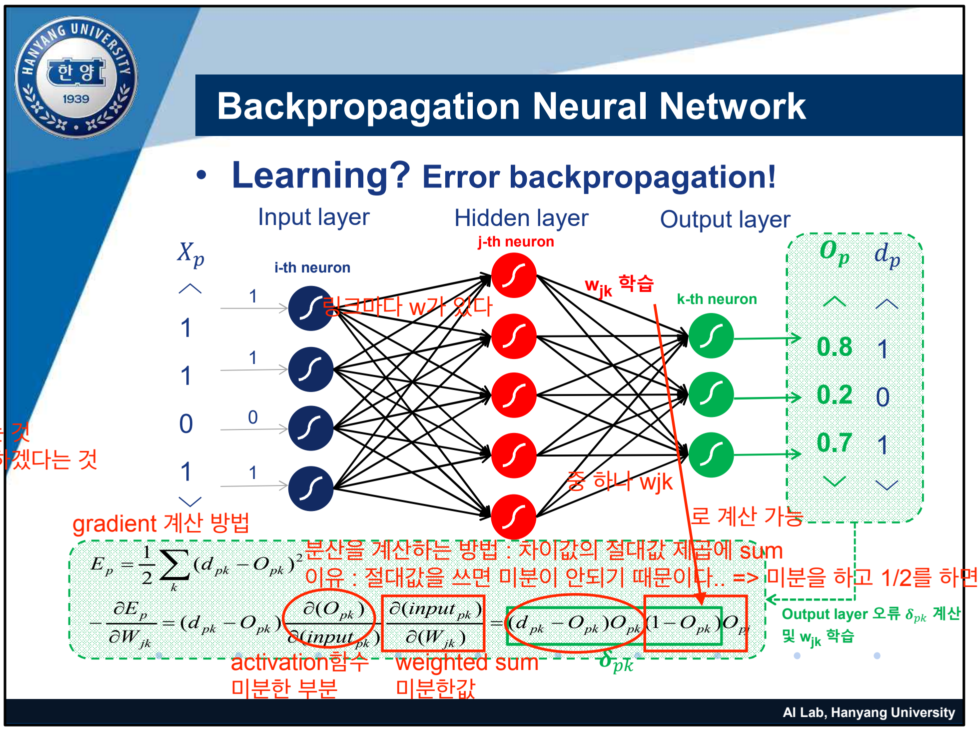

activation함수 : y = 1/(1+e^(-x))
미분 (알파y/알파x) = y(1-y) : 깔끔

표준편차의 정의는 설명할 수 있으나
표준편차의 '값'이 무엇을 뜻하는지는 설명하기 어렵다

~
처음에는 어렵게 느껴지는데 그냥 한번만 미분하면 쉬워진다구리

Backpropagation Neural Network

- **Learning? Error backpropagation!**

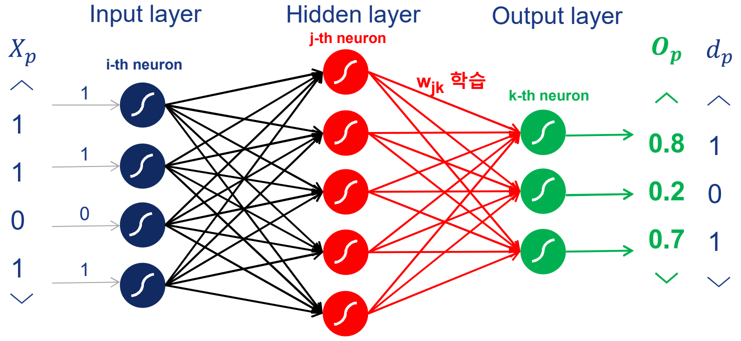

$$W_{jk}(t+1) = W_{jk}(t) + \eta * \delta_{pk} * O_{pj}$$

Backpropagation Neural Network

- **Learning? Error backpropagation!**

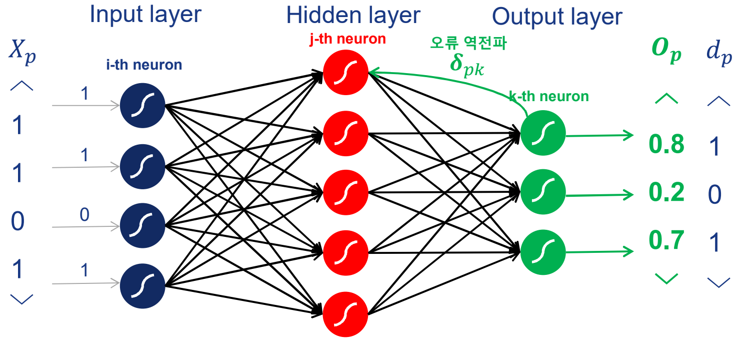

Backpropagation Neural Network

- **Learning? Error backpropagation!**

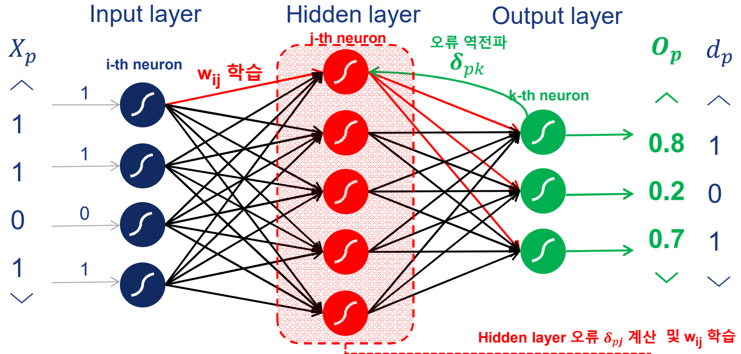

막~ 미분하고 다시 정리하면

$$-\frac{E_p}{\partial W_{ij}} = \sum_{k=0}^{M-1}(d_{pk} - O_{pk})\frac{\partial(O_{pk})}{\partial(input_{pk})}\frac{\partial(input_{pk})}{\partial(O_{pj})}\frac{\partial(O_{pj})}{\partial(input_{pj})}\frac{\partial(input_{pj})}{\partial(W_{ij})}$$

$$= \underbrace{\boxed{\sum_{k=0}^{M-1}\delta_{pk}W_{jk}O_{pj}(1-O_{pj})}}_{\delta_{pj}}X_{pi}$$

AI Lab, Hanyang University

앞쪽에 있다

Backpropagation Neural Network

- **Learning? Error backpropagation!**

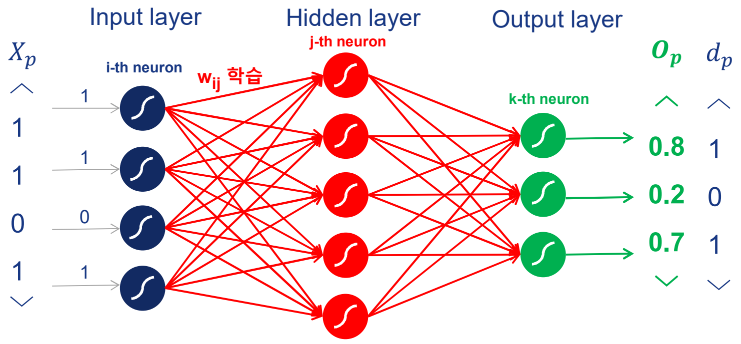

$$W_{ij}(t+1) = W_{ij}(t) + \eta * \delta_{pj} * X_{pi}$$

AI Lab, Hanyang University

Backpropagation Neural Network

- **Learning? Error backpropagation!**

Activation function → Sigmoid function

1. 가중치(W)와 임계치(θ)를 초기화
2. 입력(X)과 목표 출력(d) 을 제시
3. 제시된 입력벡터를 이용하여 hidden layer j번째 뉴런으로의 입력값 계산

$$Input_{pj} = \sum_{i=0}^{N-1} X_{pi} W_{ij} - \theta_j$$

4. Sigmoid function를 사용하여 hidden layer의 출력(O_{pj})을 계산

$$O_{pj} = f(Input_{pj})$$

5. hidden layer의 출력을 이용하여 output layer 뉴런 k로의 입력값을 계산
6. Sigmoid function을 사용하여 output layer의 출력(O_{pk})을 계산

$$O_{pk} = f(Input_{pk})$$

Backpropagation Neural Network

- **Learning? Error backpropagation!**

Activation function → Sigmoid function

7. 신경망 가중치 Gradient (각 가중치 W에 대한 E_p의 변화율)를 구한다.

$$-\frac{\partial E_p}{\partial W_{jk}} = (d_{pk} - O_{pk}) \frac{\partial(O_{pk})}{\partial(input_{pk})} \frac{\partial(input_{pk})}{\partial(W_{jk})} = \underbrace{\boxed{(d_{pk} - O_{pk}) O_{pk} (1 - O_{pk})}}_{\delta_{pk}} O_{pj}$$

$$-\frac{\partial E_p}{\partial W_{ij}} = \sum_{k=0}^{M-1} (d_{pk} - O_{pk}) \frac{\partial(O_{pk})}{\partial(input_{pk})} \frac{\partial(input_{pk})}{\partial(O_{pj})} \frac{\partial(O_{pj})}{\partial(input_{pj})} \frac{\partial(input_{pj})}{\partial(W_{ij})}$$

$$= \sum_{k=0}^{M-1} (d_{pk} - O_{pk}) O_{pk} (1 - O_{pk}) W_{jk} O_{pj} (1 - O_{pj}) X_{pi}$$

$$= \underbrace{\boxed{\sum_{k=0}^{M-1} \delta_{pk} W_{jk} O_{pj} (1 - O_{pj})}}_{\delta_{pj}} X_{pi}$$

이 슬라이드를 알면 backpropagation을 알게된다

① $E_p = \frac{1}{2} \sum_k (d_{pk} - O_{pk})^2$

② $\frac{\partial(input_{pk})}{\partial W_{jk}} = O_{pj}, \quad \frac{\partial(input_{pk})}{\partial O_{pj}} = W_{jk}$

③ $\frac{\partial(input_{pj})}{\partial(W_{ij})} = x_{pi}$

④ $y = f(x) = \frac{1}{1 + e^{-x}} \quad \therefore \frac{\partial y}{\partial x} = y(1 - y)$

Backpropagation Neural Network

- **Learning? Error backpropagation!**

8. Gradient Descent 기법으로 Hidden-Output연결 가중치를 갱신한다.

$$W_{jk}(t+1) = W_{jk}(t) + \eta * \delta_{pk} * O_{pj}$$

에타

9. Gradient Descent 기법으로 Input-Hidden연결 가중치를 갱신한다.

$$W_{ij}(t+1) = W_{ij}(t) + \eta * \delta_{pj} * X_{pi}$$

10단계. 모든 학습쌍에 대하여 전부 학습 할 때까지 2로 분기하여 반복 수행한다.

12단계. 출력층의 오차합 E가 허용값 이하이거나 최대 반복회수보다 크면 종료, 그렇지 않으면 2로 가서 다시 반복한다.

15개의 데이터주고 이걸 찾아내라~
=> 어떻게 하느냐? 신경망을 사용해서
아래와 같이 20,000회 학습 후 찾아낸다

총 7개의 perceptron, weight도 얼마 안된다
이렇게 심플함에도 불구하고 훌륭한 결과!

- 함수 근사화(function approximation)

출력값

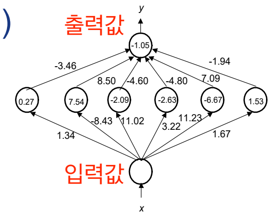

입력값

$$y = 0.5(\cos 8x + \sin 4x - x + 0.8)$$

- 위 관계식으로부터 생성된 임의의 15새 (x,y)쌍을 학습 데이터로 사용 (*학습데이터: 아래 그림의 점)
- 입력층 : 1개 뉴런
- 은닉층 : 6개 뉴런
- 출력층 : 1개 뉴런 사용

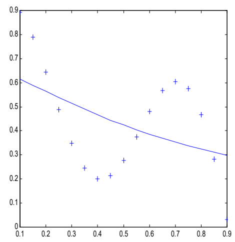

주어진 데이터로 1,000회 학습 후

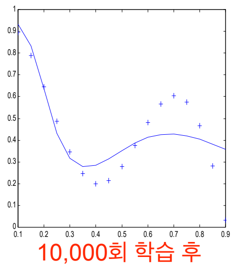

10,000회 학습 후

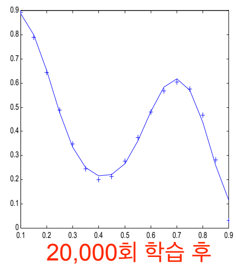

20,000회 학습 후

Backpropagation Neural Network

- **Example**

https://www.youtube.com/watch?v=6lgAzEomn-4

오늘 한 부분은 리뷰 꼭~~ 하세용

5. Hopfield memory

Types of simple ANNs

입력형식	학습방식	Artificial neural network model
이진입력	지도(supervised) 학습	인풋과 아웃풋 벡터가 거의 동일..? Hopfield memory, BAM
실수입력 real data	지도(supervised)학습	Perceptron, Backpropagation neural network
	비지도(unsupervised) 학습	Self-Organizing Map(SOM)

< ANN 모델 분류 예 >

Hopfield memory

- **What is Hopfield memory?**

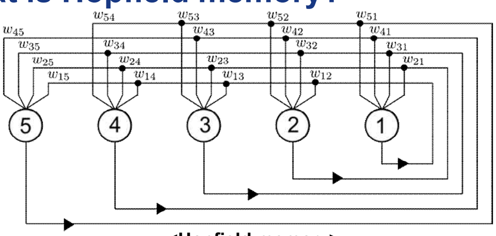

<Hopfield memory> 나머지 모든 뉴런의 입력으로 주겠다

- Hopfield memory는 자신을 제외한 모든 뉴런과 양방향으로 상호 연결된 형태의 ANN
- Activation function으로 hard limiter를 사용
- 기본 모델은 bipolar 값(+1, -1)을 사용
- 연상기억 또는 최적화 문제를 푸는데 주로 사용
- 다른 종류의 ANN model과 달리 점진적 학습을 하지 않고, 초기 학습패턴의 외적합(sum of outer product)을 사용하여 연결가중치를 만듦
- 하나의 뉴런층을 사용하므로 입력벡터와 출력벡터의 차원이 동일(Auto associative Memory)

i j는 달라야하고 (같은거에서 만들어지면 안된다)
wij 는 외적합을 통해서 만들어진다.

Hopfield memory

- What kind of problem can I solve with Hopfield memory?

연상 기억 문제 (ex.필기인식)

이미지 인식

사람은 필체가 모두 다르기 때문에 다르게 나올 수 있다
그러나 이렇게 이게 뭐다! 하는 방법은?
hopfield memory!

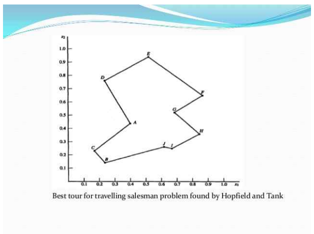

최적화 문제 (ex.Traveling salesman problem)

자료구조..에 나온 것인가보당..

Hopfield memory

- How does Hopfield memory work?

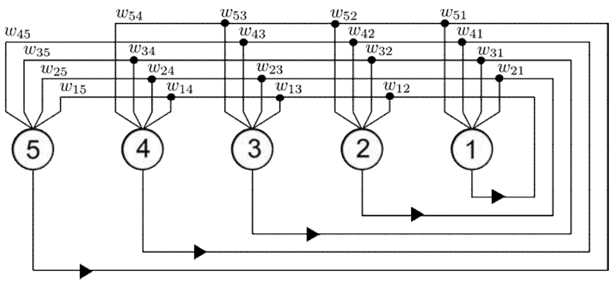

<Hopfield memory>

Hopfield memory

- **How does Hopfield memory work?**

Activation function → Hard limiter

1. M개의 패턴을 이용하여 N개 뉴런 사이의 연결 가중치를 지정
   (W_{ij} 는 뉴런i에서 뉴런j로의 연결 가중치)

$$\boxed{W_{ij} = \begin{cases} \sum_{s=0}^{M-1} X_i^S X_j^S \ (i \neq j) \\ 0 \ (i = j) \end{cases} \qquad 0 \le i,j \le N-1}$$

2. 미지의 입력 패턴을 Hopfield memory에 제시

$$\mu_j(0) = x_i \qquad 0 \le i \le N-1$$

3. 뉴런들의 출력과 가중치를 곱한 값을 합하여 Activation function을 통과시킴

$$\mu_j(t+1) = f_b\left(\sum_{i=0}^{N-1} W_{ij} * \mu_i(t)\right) \qquad 0 \le i \le N-1$$

4. 수렴(뉴런의 출력 변화가 없는 상태)할 때까지 3을 반복

D

Hopfield memory

- **Learning(Hopfield memory)**

Example

1 4 : 부호반대
2 3 : 부호같음

1. 두 개의 학습 패턴 $P_0 =< 1,1,1,-1 >, P1 =< 1,-1,1,-1 >$을 Hopfield memory에 제시

서로다른 ㅜ이치 곱을 한 다음에 패턴별로 곱

2. $$W_{ij} = \begin{cases} \sum_{s=0}^{M-1} X_i^S X_j^S \ (i \neq j) \\ 0 \ (i = j) \end{cases} \qquad 0 \le i,j \le N-1$$

→ $W_{01} = X_0^0 X_1^0 + X_0^1 X_1^1 = (1 \times 1) + (1 \times (-1))$

$W_{02} = X_0^0 X_2^0 + X_0^1 X_2^1 = (1 \times 1) + (1 \times 1)$

$W_{03} = X_0^0 X_3^0 + X_0^1 X_3^1 = (1 \times (-1)) + (1 \times (-1))$

…

(0,1)
p0 : 1, 1
p1 : 1, -1

(2,0)
p0 : 1, 1
p1 : 1 1

(0.3)
P0 : 1, -1
p1 : 1, -1

$$W = \begin{bmatrix} 0 & 0 & 2 & -2 \\ 0 & 0 & 0 & 0 \\ 2 & 0 & 0 & -2 \\ -2 & 0 & -2 & 0 \end{bmatrix}$$

-1이 들어가는지 1이 들어가는지
뭐가 나오는지
서로가느이 assosiation을 파악하는 것이 W

component간의 곱을 본다는게 부호를 본다는 것!
w이 -쪽으로 커진다는 것은 부호가 반대가 되도록.. 패턴이 그렇게 된다는 것

Hopfield memory

- **Learning(Hopfield memory)**

Example

3. 새로운 입력 패턴 P_{new} $=< 1,1,-1,-1 >$ 을 제시. 수렴할 때까지 W행렬과 곱해줌

(a) $\mu_0(0) = 1, \mu_1(0) = 1, \mu_2(0) = -1, \mu_3(0) = -1$

(b) $\mu_j(t+1) = f_b(\sum_{i=0}^{N-1} W_{ij} * \mu_i(t)) \quad 0 \le i \le N-1$

(c) $\mu(1) = [1\ 1\ \ -1\ \ -1] * \begin{bmatrix} 0 & 0 & 2 & -2 \\ 0 & 0 & 0 & 0 \\ 2 & 0 & 0 & -2 \\ -2 & 0 & -2 & 0 \end{bmatrix} = f_b([0\ 0\ 4\ 0]) = [1\ 1\ 1\ 1]$

$\mu(2) = [1\ \ 1\ \ 1\ \ 1] * \begin{bmatrix} 0 & 0 & 2 & -2 \\ 0 & 0 & 0 & 0 \\ 2 & 0 & 0 & -2 \\ -2 & 0 & -2 & 0 \end{bmatrix} = f_b([0\ 0\ 0\ -4]) = \boxed{[1\ 1\ 1\ -1]}$

$P_0 =< 1, 1, 1, -1 >$에 수렴

Hopfield memory

- 패턴이미지 크기: (5x5) 대상 : {ㄱ, ㄴ, ㄷ, ㄹ}으로 학습

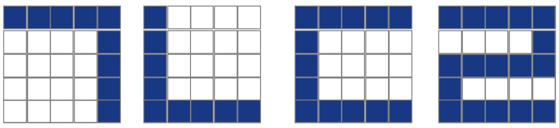

ㄱ이랑 비슷한 것은 ㄱ으로 수렴...
similarity가 비슷한 쪽으로 수렴하게 된다

- 회로망 크기에 대한 저장 가능한 패턴수 문제
  - Hopfield에서는 뉴런 수가 N인 경우 일반적으로 0.15N개의 패턴 기억 가능
  - 이 예제의 경우 25x0.15 = 3.75 → 4개 미만의 패턴 인식
- Hopfield 신경망의 큰 문제점은 수렴결과가 최적인지 보장 안됨
  - 잘못된 기억을 연상해 낼 수 있음

Hopfield memory

- **Example of Hopfield memory**

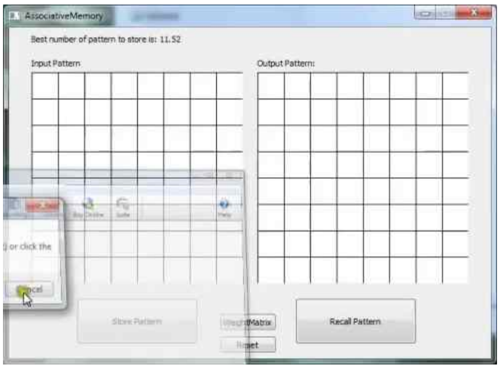

https://www.youtube.com/watch?v=EGazcWEJGuY

7. Self Organizing Map(SOM)

Self Organizing Map(SOM)

입력형식	학습방식	Artificial neural network model
이진입력	지도학습	Hopfield memory, BAM
실수입력	지도학습	Perceptron, Backpropagation neural network
	비지도학습	**Self-Organizing Map(SOM)**

<ANN 모델의 분류>

Self Organizing Map (SOM)

- **What is SOM?**

<Self Organizing Map>

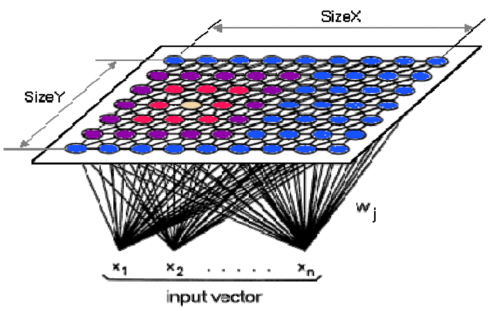

- 인접한 출력뉴런들은 비슷한 기능을 수행할 것이라는 예측 (뇌의 부분에 따라 인지 기능의 종류가 다르고, 뇌의 비슷한 부분은 비슷한 인지 기능을 수행한다는 가정)
- 입력벡터와 가장 가까운 출력뉴런(승자뉴런) 뿐만 아니라 위상적으로 이웃한 뉴런들도 함께 학습시킴

Self Organizing Map(SOM)

- **What kind of problem can I solve with SOM?**

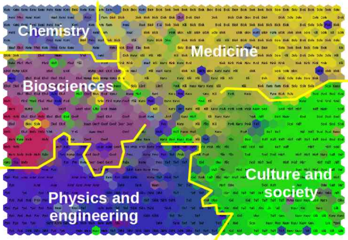

Clustering & Classification

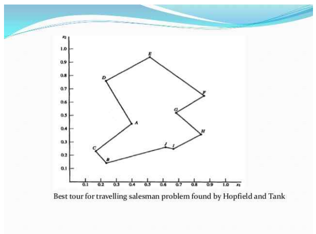

최적화 문제 (ex.Traveling salesman problem)

Self Organizing Map(SOM)

- **Learning (SOM)**

1. 연결가중치를 초기화
→ N개의 입력으로부터 M개의 출력 뉴런 사이의 연결강도를 임의의 값으로 초기화

2. 새로운 입력패턴을 입력뉴런에 제시한다.

3. 입력벡터와 모든 출력뉴런들과의 거리(입력벡터와 가중치벡터의 거리)를 계산

벡터의 방향이 일치할수록 1, 반대일수록 -1, 음소거일수록 0
weight 벡터를 다 비교를 해서 가장 weighted sum이 높게나오는게 뉴런의 값(?)
그놈이 제일 높게 나오는걸 계산하려면 distance를 계산하면 된다

$$d_j = \sum_{i=0}^{N-1} (X_i(t) - W_j(t))^2$$

4. 최소거리를 가지는 승자뉴런을 구함. d_j가 최소인 출력 뉴런 j*를 선택

Self Organizing Map(SOM)

- **Learning (SOM)**

5. 뉴런 j*와 그 이웃 반경내의 뉴런들의 연결강도를 다음 식에 의해 재조정

$$W_j\,(t+1) = W_j\,(t) + \alpha(x_i(t) - W_j\,(t))$$

→여기서 j는 j*의 이웃 반경내의 모든 뉴런

6. 2로 가서 모든 입력벡터를 처리

7. 지정된 학습회수까지 <u>이웃 반경을 점차 감소시키면서</u> 2부터 6의 과정을 충분한 횟수 반복

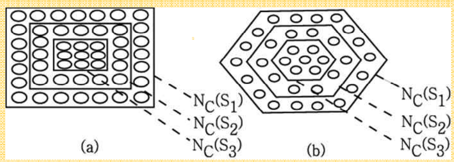

Self Organizing Map(SOM)

- **Learning (SOM, Example)**

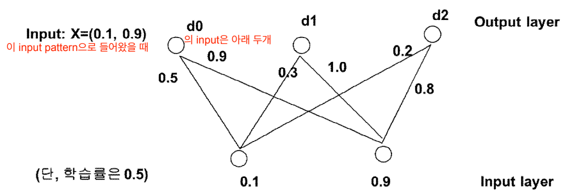

- d_0 = (0.1-0.5)^2 + (0.9-0.9)^2 = 0.16, d_1 = 0.05, $\boldsymbol{d_2}$ = **0.02(승자뉴런)**
- d_2 의 연결 가중치 조정

$W_{02}(t+1)$ = **0.2+0.5(0.1-0.2) =0.15**
$W_{12}(t+1)$ = **0.8+0.5(0.9-0.8) =0.85**

→ 제시된 입력과 가장 유사한 출력뉴런의 가중치벡터가 입력을 향하여 이동
→ d_2 의 이웃 뉴런들 역시 동일하게 학습

Self Organizing Map(SOM)

- **Example of SOM(TSP problem)**

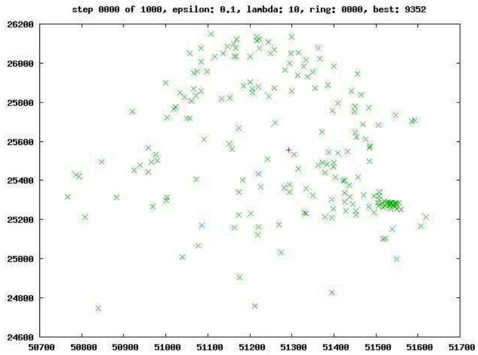

https://www.youtube.com/watch?v=8tnxgfE6glI

THANK YOU!